

Maestría en Inteligencia Artificial
Aprendizaje de Máquina

Feature Selection

Selección de Características — Breast Cancer Wisconsin

Fecha: 10 de June de 2026

Dataset: Breast Cancer Wisconsin (Diagnostic) · scikit-learn

Herramienta: Python 3 · scikit-learn · reportlab

1. Modelado

1.1 Descripción del Dataset

El **Breast Cancer Wisconsin (Diagnostic) Dataset** contiene características numéricas computadas a partir de imágenes digitalizadas de biopsias celulares. Incluye **569 muestras** y **30 características**. La variable objetivo es binaria: **0 = Maligno** (212) · **1 = Benigno** (357).

Las 30 características representan media, error estándar y valor extremo de 10 propiedades morfológicas: radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal.

1.2 Preprocesamiento

- **División:** 70 % entrenamiento (398) / 30 % prueba (171) · stratify=y · random_state=42
- **Escalado:** StandardScaler (media=0, STD=1) — ajustado solo en train
- **Métrica principal:** Recall — minimiza Falsos Negativos en diagnóstico médico

1.3 Clasificador Base

Todos los métodos se evalúan con **LogisticRegression** (max_iter=10000, solver=lbfgs, random_state=42). Esto aísla el efecto de la selección de características.

2. Algoritmos de Selección

2.1 Baseline — Sin Selección

Modelo entrenado con las 30 características originales. Referencia de rendimiento.

2.2 Filter — SelectKBest + Información Mutua

Puntúa cada característica por $I(X;Y) = \sum p(x,y) \cdot \log[p(x,y)/(p(x) \cdot p(y))]$. Captura relaciones no lineales. Parámetros: **score_func=mutual_info_classif, k=17**.

2.3 Wrapper — RFE (Recursive Feature Elimination)

Entrena el modelo iterativamente y elimina la feature con menor |coeficiente|. Parámetros: **estimator=LogisticRegression, n_features_to_select=10, step=1**.

2.4 Embedded — Regresión Logística L1 (LASSO)

La penalización L1 lleva coeficientes exactamente a 0. Parámetros: **penalty='l1', solver='saga', C=0.20** (GridSearchCV KFold-5, scoring=recall). Umbral de selección: |coef| > 1e-5.

2.5 Híbrido — Filter + Wrapper

Etapas: 1: SelectKBest-MI reduce 30 → 17 (rápido). 2: RFE refina 17 → 10 (iterativo). Menor costo que RFE puro.

2.6 Borda Voting — Ensemble de Consenso

Cada método rankea las N features. El método m asigna (N – rango_i) puntos a feature i. Puntuaciones sumadas; se toman las top 10.

- MI: puntuación de información mutua
- RFE: ranking inverso de eliminación
- LassoCV: |coeficientes| (cv=5, max_iter=10000)
- Random Forest: feature_importances_ (n_estimators=500)

3. Resultados

3.1 Tabla Comparativa

Fila verde = mejor Recall. El baseline usa 30 features como referencia.

Método	N Feat.	Accuracy	Precision	Recall	F1	ROC-AUC
Baseline	30	0.9883	0.9907	0.9907	0.9907	0.9981
Filter	17	0.9649	0.9550	0.9907	0.9725	0.9974
Wrapper	10	0.9708	0.9722	0.9813	0.9767	0.9926
Embedded	8	0.9708	0.9636	0.9907	0.9770	0.9950
Hybrid	10	0.9708	0.9636	0.9907	0.9770	0.9949
Borda	10	0.9708	0.9636	0.9907	0.9770	0.9901

Tabla 1. Métricas por método de selección de características.

3.2 Barras Comparativas




Figura 1. Recall, F1, AUC y Accuracy por método.




Figura 2. Radar de rendimiento.

3.3 Curvas ROC




Figura 3. Curvas ROC de todos los métodos.

3.4 Recall vs. N° Características




Figura 4. Recall como función del número de features seleccionadas.

3.5 Importancia de Características

3.5.1 Filter — Información Mutua




Figura 5. Puntuaciones de MI para las 30 características.

3.5.2 Wrapper — RFE




Figura 6. Ranking RFE (mayor = más importante).

3.5.3 Embedded — LASSO




Figura 7. Magnitud de coeficientes L1 (C=0.20).

3.5.4 Borda Voting — Consenso








Figura 8. Puntuación Borda acumulada de 4 métodos.


3.6 Matrices de Confusión

Falsos Negativos (FN) son los errores más críticos en diagnóstico oncológico.






Matriz — Embedded



Matriz — Hybrid



Matriz — Borda

3.7 Mapa de Consenso




Figura 9. Rojo oscuro = feature seleccionada por ese método.

3.8 Top 10 Features — Borda Voting

#	Característica	Borda Score
1	worst radius	116
2	worst area	113
3	worst concave points	112
4	mean concave points	92
5	worst perimeter	91
6	worst concavity	85
7	mean compactness	83
8	worst texture	82
9	mean concavity	81
10	mean radius	77

Tabla 2. Features seleccionadas por Borda Voting.

4. Conclusiones

4.1 Comparación de Características

Los métodos coinciden en destacar características relacionadas con el tamaño y forma de los núcleos (**worst radius, worst area, worst concave points, mean concave points**). Las variantes *worst* son consistentemente seleccionadas por múltiples métodos, confirmando su relevancia diagnóstica.

4.2 Comparación de Rendimiento

5 de 6 métodos alcanzan Recall = 0.9907 usando entre 8 y 17 características (vs. 30 del Baseline). LASSO logra el mayor parsimonismo: **8 features, igual Recall** que el baseline.

4.3 Ventajas del Borda Voting

- Robusto: combina 4 criterios con distintos sesgos algorítmicos
- Reduce dependencia de hiperparámetros individuales
- Transparente: la puntuación Borda es interpretable directamente
- Complementario: estadístico (MI) + iterativo (RFE) + lineal (LASSO) + ensamble (RF)

4.4 Limitaciones

- Asume pesos iguales para todos los métodos
- Mayor costo computacional: entrena 4 modelos/criterios
- Sensible al total de features N; features irrelevantes distorsionan el ranking

4.5 Conclusión General

La selección de características permite **reducir de 30 a 8–10 variables** sin sacrificar sensibilidad diagnóstica. Borda Voting emerge como estrategia robusta de consenso. En entornos clínicos se recomienda complementar este análisis con validación experta de las features seleccionadas.